Machine learning cheatsheet

Alexis GRACIAS

9 novembre 2026

Table des matières

1 Définitions générales . . . 3
- 1.1 Notations . . . 3
- 1.2 Fonction de perte . . . 4
- 1.3 Fonction de décision . . . 4
- 1.4 Risque . . . 5
  - 1.4.1 Risque réel . . . 5
  - 1.4.2 Risque empirique . . . 5
  - 1.4.3 Un problème d'optimisation . . . 5
- 1.5 Définition formelle d'un jeu de données . . . 5

2 Les différents types d'apprentissage . . . 7
- 2.1 Apprentissage supervisé . . . 7
- 2.2 Apprentissage non supervisé . . . 7
- 2.3 Apprentissage auto-supervisé . . . 7
- 2.4 Apprentissage semi-supervisé . . . 7
- 2.5 Apprentissage par renforcement . . . 7

3 Métriques . . . 8
- 3.1 Introduction . . . 8
- 3.2 Métriques usuelles pour les problèmes de régression . . . 8
- 3.3 Métriques usuelles pour les problèmes de classification . . . 8

4 Synthèse des modèles et leurs usages . . . 10

5 Mathématiques complémentaires . . . 14
- 5.1 Motivations . . . 14
- 5.2 Distance, normes et produits scalaires . . . 14
  - 5.2.1 Distance. . . . 14
  - 5.2.2 Norme. . . . 14
  - 5.2.3 Produit scalaire . . . 14

5.2.4 Produit hermitien 16
5.3 Topologie 16
5.3.1 Complétude. 16
5.3.2 Corps commutatif. 16
5.3.3 Espace topologique. 18
5.3.4 Espace métrique. 18
5.3.5 Espace vectoriel normé. 18
5.3.6 Espace euclidien. 18
5.3.7 Espace hermitien. 18
5.3.8 Espace de Banach. 18
5.3.9 Espace de Hilbert ou hilbertien et préhilbertien. 18
5.3.10 Espace ouvert et fermé. 19
5.3.11 Espace L^p 20
5.3.12 Espace de Sobolev. 20
5.3.13 Notion de voisinage. 21
5.4 Intégrabilité 21
5.4.1 Intégrabilité (Riemann). 21
5.4.2 Intégrabilité (Lebesgue). 21
5.5 Distributions. 21
5.5.1 Support compact. 21
5.5.2 Fonction test 22
5.5.3 Théorie des distributions. 22
5.6 Théorie de l'apprentissage 23
5.6.1 Apprentissage PAC. 23
5.7 Complétude, tribu, mesure 23
5.7.1 Complémentarité. 23
5.7.2 Tribu. 24
5.7.3 Espace mesurable 24
5.7.4 Tribu image réciproque 24
5.7.5 Fonction mesurable 24
5.7.6 Fonction différentiable. 24
5.7.7 Gradient. 25
5.7.8 Application Lipschitzienne. 25
5.7.9 ∇f Lipschitz continuité. 25
5.8 Autre 26
5.8.1 Théorème fondamental des splines de lissage - Théorème de représentation. 26

1 | Définitions générales

1.1 Notations

Nous noterons, dans tout le document et sans ambiguïté, $\mathcal{Y}$ et $\mathcal{X}$ les espaces d'entrées (ou d'observation) et de sortie du modèle $h \in \mathcal{H}$ respectivement. $\mathcal{H}$ est l'espace des hypothèses. En théorie de l'apprentissage statistique, un estimateur $h \in \mathcal{H}$ est une fonction de $\mathcal{X}$ dans $\mathcal{Y}$ qui donne une approximation de la vérité terrain $\boldsymbol{y}$, que nous noterons $\hat{\boldsymbol{y}}$. Ainsi, $\hat{\boldsymbol{y}} = h(\boldsymbol{x}), \boldsymbol{x} \in \mathcal{X}$. C'est en d'autres termes la fonction de décision prise par le modèle pour approximer la valeur de $\boldsymbol{y}$. C'est une hypothèse faite par le modèle sur les données pour modéliser un comportement en tenant compte des données.

Notons que le modèle d'apprentissage peut être muni d'un ensemble de paramètres $\boldsymbol{\theta} \in \Theta$. Nous noterons alors un estimateur h muni de paramètres $\boldsymbol{\theta} \in \Theta \quad h_{\boldsymbol{\theta}} \in \mathcal{H}$. Nous disposons par conséquent de deux cas de figure, à savoir d'une part les modèles génératifs, notés $h_{\boldsymbol{\theta}} = h(\boldsymbol{\theta})$, qui génèrent une sortie sans réclamer de variable d'entrée $\boldsymbol{x} \in \mathcal{X}$, et d'autre part les modèles discriminatifs, qui, eux, réclament des données d'entrées $\boldsymbol{x}$ pour la classification ou régression. Nous noterons alors les modèles discriminatifs $h_{\boldsymbol{\theta}}(\boldsymbol{x}) = h(\boldsymbol{\theta}, \boldsymbol{x})$.

En d'autres termes, les modèles génératifs modélisent la distribution conjointe $p(x, y)$ pour générer de nouveaux échantillons, tandis que les modèles discriminatifs modélisent la distribution conditionnelle $p(y|x)$ pour prédire ou classifier un problème à partir de données d'entrée.

ℓ est la fonction de perte. C'est une mesure de l'écart entre la valeur prédite et la vérité terrain. $\mathcal{R}_{\text{emp}}$ et $\mathcal{R}$ sont respectivement le risque empirique et le risque réel.

- $\mathcal{X}$: espace d'entrées (observations)
- $\mathcal{Y}$: espace des sorties
- $\mathcal{H}$: espace des hypothèses
- Θ : espace des paramètres
- $h_{\boldsymbol{\theta}}$: fonction de décision ou estimateur
- ℓ : fonction de perte
- $\mathcal{R}_{\text{emp}}$: risque empirique
- $\mathcal{R}_S$: risque réel

1.2 Fonction de perte

La fonction de perte est la fonction qui permet de mesurer l'écart entre la valeur prédire *a priori* et la valeur réelle à trouver (la vérité terrain). Mathématiquement, ℓ est une fonction telle que

$$\begin{array}{rccl} \ell: & \mathcal{Y}\times\mathcal{Y} & \longrightarrow & \mathbb{R} \\ & (\boldsymbol{y},\hat{\boldsymbol{y}}) & \longmapsto & \ell(\boldsymbol{y},\hat{\boldsymbol{y}})=\ell(\boldsymbol{y},h(\boldsymbol{x})) \end{array} \tag{1.1}$$

En pratique, cette fonction doit pouvoir être mesurable d'espérance définie, de telle sorte à optimiser le risque 1.4. Pour un problème de régression linéaire, nous utilisons usuellement la méthode des moindres carrés, à savoir

$$\ell_{\text{OLS}}(\boldsymbol{y},\underbrace{\hat{\boldsymbol{y}}}_{h(\boldsymbol{x})})=\frac{1}{n}\sum_{i=1}^{n}(\underbrace{\hat{y_i}}_{h(x_i)}-y_i)^2$$

Nous avons donc dans ce cas particulier $\boldsymbol{y}\in\mathcal{Y}=\mathbb{R}^n$ et $\boldsymbol{x}\in\mathcal{X}=\mathbb{R}^d$ avec n et d deux entiers pas nécéssairement égaux.

1.3 Fonction de décision

La fonction de décision est une fonction qui prend en paramètres les données et paramètres du modèle et retourne une valeur qui correspond à l'estimateur $\hat{\boldsymbol{y}}$ de $\boldsymbol{y}$. C'est la fonction globale du modèle, ou fonction de transfert, qui établit la relation entre l'entrée et la sortie du modèle. En apprentissage profond, cette fonction n'est pas à confondre avec la fonction d'activation qui représente la dernière étape de l'architecture d'un modèle d'apprentissage profond.

$$\begin{array}{rccl} h_{\boldsymbol{\theta}}: & \Theta\times\mathcal{X} & \longrightarrow & \mathcal{Y} \\ & (\boldsymbol{\theta},\boldsymbol{x}) & \longmapsto & h_{\boldsymbol{\theta}}(\boldsymbol{x})=h(\boldsymbol{\theta},\boldsymbol{x}) \end{array} \tag{1.2}$$

A titre d'exemple, pour une régression linéaire, $h_{\boldsymbol{\theta}}(\boldsymbol{x})=\boldsymbol{\omega}^T\boldsymbol{x}+b$, avec T l'opérateur transpose sur $\mathbb{R}$. Par conséquent $\boldsymbol{\theta}=(\boldsymbol{\omega},b)\in\mathbb{R}^d\times\mathbb{R}$. L'espace des hypothèses, $\mathcal{H}$, est l'ensemble de ces fonctions de décision.

$$\mathcal{H}=\{h_{\boldsymbol{\theta}}|\boldsymbol{\theta}\in\Theta\} \tag{1.3}$$

Pour une régresion linéaire dont les données d'entrées sont $\boldsymbol{x}=(x_1,x_2)^T$, les poids de la régression et le biais, i.e. les paramètres $\boldsymbol{\theta}=((\omega_1,\omega_2)^T,b)$ valent *a posteriori* $\boldsymbol{\theta}=((1;4)^T,2)$ (vérité terrain), nous aurions

$$\begin{aligned} \mathcal{H} &= \left\{h_{\boldsymbol{\theta}}=\boldsymbol{\omega}^T\boldsymbol{x}+b \quad | \quad \boldsymbol{\theta}=(\boldsymbol{\omega},b)\in\Theta\right\} \\ &= \{(x_1,x_2)\mapsto\omega_1x_1+\omega_2x_2+b \quad | \quad \boldsymbol{\theta}=(\omega_1,\omega_2,b)\in\Theta\} \end{aligned}$$

avec des estimateurs $h_{\boldsymbol{\theta}_i}$ dont les paramètres seraient $((1,1;3,95)^T;2,2)$, $((1,5;3,8)^T;2,01)$ ou $((0,5;4,3)^T;2,1)$ par exemple. Parmis tout ces estimateurs, le meilleur est celui qui minimise le risque empirique 1.4 sur l'ensemble des paramètres $\boldsymbol{\theta}$, le risque réel n'étant pas accessible.

Pour un problème d'appprentissage profond, nous considérons un réseau de neuronnes à L couches, d'entrée $\boldsymbol{x} \in \mathbb{R}^{n_0}$ et de sortie $\boldsymbol{y} \in \mathbb{R}^{n_L}$, n_l étant le nombre de neuronnes à la couche l. La sortie de la couche $l \in \{1; L\}$ (représentation intermédiaire) est

$$h^{(l)} = \sigma_l \left(W_l h^{(l-1)} + b_l\right) \in \mathbb{R}^{n_l}$$

avec σ_l la fonction d'activation (tanh, sigmoïde, ReLU), $W_l \in \mathbb{R}^{n_l \times n_{l-1}}$ la matrice des poids, $b_l \in \mathbb{R}^{n_l}$ le vecteur des bais de la couche l. Il vient que $h^{(0)} = \boldsymbol{x}, h^{(1)} = \sigma_1 \left(W_1 h^{(0)} + b_1\right)$, $h^{(2)} = \sigma_2 \left(W_2 h^{(1)} + b_2\right)$, ..., $h^L = \sigma_L \left(W_L h^{(L-1)} + b_L\right) = h_{\boldsymbol{\theta}}$. σ_l est par conséquent une fonction d'activation, ou de sortie locale, mais n'est pas la fonction de décision (fonction globale) que nous pouvons réécrire comme

$$h_{\boldsymbol{\theta}}(\boldsymbol{x}) = (\sigma_L \circ g_L \circ \ldots \circ \sigma_1 \circ g_1)(\boldsymbol{x})$$

Avec $g_l(\boldsymbol{z}) = W_l \boldsymbol{z} + b_l$ et $\boldsymbol{\theta} = (W_1, b_1, \ldots, W_L, b_L)$.

1.4 Risque

1.4.1 Risque réel

Soit D la distribution *a priori* inconnue des données

1.4.2 Risque empirique

1.4.3 Un problème d'optimisation

La fonction de perte est la fonction objectif que nous cherchons à minimiser. Le Fondamentalement, un problème d'apprentissage automatique se ramène à un problème d'optimisation **??**

1.5 Définition formelle d'un jeu de données

Soit $\mathcal{D}$ un jeu de données (ou *dataset*) de N échantillons (ou réalisations) i.i.d, J variables, i.e.

$$\mathcal{D} \stackrel{\text{def}}{:=} \{(X_i, y_i) \quad | \quad x_i, y_i \in \mathcal{X} \times \mathcal{Y}, \quad \forall i \in \mathbb{N}\} \tag{1.4}$$

Avec :

- $X_i \in \mathbb{R}^n, X_i = (x_{i,1}, \ldots, x_{i,J})$: i-ème échantillon du dataset, $i \in \{1; N\}$.
- $y_i \in \mathbb{R}$: i-ème réalisation de la variable cible. C'est la variable que nous cherchons à modéliser.

Ainsi, $\mathcal{D} = (\boldsymbol{X}, \boldsymbol{y})$ avec $\boldsymbol{X} = (X_i)_{i \in \{1;n\}}$ et $\boldsymbol{y} = (y_i)_{i \in \{1;n\}}$

$$\boldsymbol{X} = \begin{bmatrix} x_{1,1} & \ldots & x_{1,J} \\ \vdots & x_{i,j} & \vdots \\ x_{n,1} & \ldots & x_{n,J} \end{bmatrix} \quad \boldsymbol{y} = \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} \tag{1.5}$$

$\mathcal{X}$ et $\mathcal{Y}$ sont respectivement les ensembles d'observation et de sortie du *dataset*. Dans le cadre de notre étude, $\boldsymbol{y}$ est la colonne du jeu de données qui correspond à la puissance totale (kW). Pour $\boldsymbol{X} \in \mathcal{X}$, c'est la matrice qui contient toutes les réalisation des variables évoquées précédement **??**. Les élément $x_{i,j}$ (nombres réels, entiers, texte) représentent une réalisation (échantillon i) de chaque variable $j \in \{1; J\}$.

2 | Les différents types d'apprentissage

2.1 Apprentissage supervisé

2.2 Apprentissage non supervisé

2.3 Apprentissage auto-supervisé

2.4 Apprentissage semi-supervisé

2.5 Apprentissage par renforcement

3 | Métriques

3.1 Introduction

Les métriques sont des indices de performance pour les modèles utilisés en apprentissage automatique (et aussi des fonctions de perte). Elles servent notament à vérifier que la prédiction faite par le modèle est juste. En effet, plus la métrique a un bon score, plus le modèle tend à être performant. En revanche, un score très élevé sur les données d'entraînement mais très faible sur les données de validation (test) peu indiquer un cas de surapprentissage ou de fuite de données.

Les métriques sont différentes en fonction du problème posé. En effet,

3.2 Métriques usuelles pour les problèmes de régression

Soient $\boldsymbol{y}, \boldsymbol{y}^{'} \in \mathcal{Y} = \mathbb{R}^N$, $h \in \mathcal{H}$ et $\boldsymbol{x} \in \mathcal{X}$ tel que $\boldsymbol{y}^{'} = h(x)$ avec $\boldsymbol{y} = [y_1, \ldots, y_N]$

- **Mean Absolute Error** :

$$L_{\text{MSE}}(\boldsymbol{y},) = \frac{1}{n} \sum_{i=1}^{n} |y_i - \hat{y}_i| \tag{3.1}$$

- **Root Mean Squarred Error** :

$$MSE(Y) = \frac{1}{n} \sum_{i=1}^{n} (y_i - \hat{y}_i)^2 \tag{3.2}$$

-

3.3 Métriques usuelles pour les problèmes de classification

- **Accuracy score** :

$$\text{Accuracy} = \frac{VP + VN}{VP + VN + FN + FP} = 1 - \text{exactitude} \tag{3.3}$$

Avec :

— VP : Vrai négatif

— FP : Faux positifs

— FN : Faux négatifs

— VP : Vrais positifs

- **Matrice de confusion**
  Une matrice de confusion recense le nombre de faux positifs, faux négatifs, vrai positifs et vrai négatifs sous forme de tableau. Les éléments de cette matrice 2×2 veulent dire ceci :

  — Vrai négatif (Réel 0, Prédit 0)

  — Faux positifs (Réel 0, Prédit 1)

  — Faux négatifs (Réel 1, Prédit 0)

  — Vrais positifs (Réel 1, Prédit 1)

  La prédiction est la valeur que le modèle prédit tandis que réel est la valeur réelle, qui peut être observée à *posteriori* Par exemple, une matrice de confusion peut ressembler à ça :

	Prédit : 0	**Prédit : 1**
Réel : 0	87	13
Réel : 1	18	61

TABLE 3.1 – Exemple de matrice de confusion

Ici, le modèle a prédit que $87 + 18 = 105$ personnes n'ont pas survécues à l'accident sur les $87 + 13 = 100$ personnes qui n'ont réellement pas survécues. De même, le modèle prédit que $13 + 61 = 74$ personnes on survécues sur $10 + 61 = 71$ qui ont réelement survécues.

4 | Synthèse des modèles et leurs usages

Modèle	**Quand l'utiliser**	**Paradigme**	**Formule**	**Quantité à minimiser**	**Préparation des données**
Régression linéaire	Relation linéaire entre X_i et X_j	Régression statistique	$\hat{y} = X\beta + \varepsilon$	$\|\|y - X\beta\|\|^2$	Standardisation
Régression Ridge	Régression avec pénalisation L_2 (sélection de variables)	Régression statistique	$\hat{y} = X\beta + \varepsilon$	$\|\|y-X\beta\|\|^2+\lambda\|\|\beta\|\|^2$	Standardisation
Régression Lasso	Régression avec pénalisation L_1 (sélection de variables avec annulation)	Régression statistique	$\hat{y} = X\beta + \varepsilon$	$\|\|y-X\beta\|\|^2+\lambda\|\|\beta\|\|_1$	Standardisation
Elastic Net	Régression Ridge + Lasso	Régression statistique	$\hat{y} = X\beta + \varepsilon$	$\|\|y - X\beta\|\|^2 + \lambda(\alpha\|\|\beta\|\|_1 + (1 - \alpha)\|\|\beta\|\|_2^2)$	Standardisation
Régression logistique	Classification binaire	Classification binaire	$\hat{y} = \sigma(X\beta)$	$-\sum y \log(\hat{y})$	Standardisation
Régression logistique multinomiale	Classification	Classification			Standardisation
Régression polynomiale	Régression non linéaire	Régression statistique	$\hat{y} = \sum_{k=0}^{d} \beta_k x^k$	$\sum_{i=1}^{n}(y_i - \hat{y_i})^2$	Standardisation
Régression splines	Régression non linéaire, robuste, locale	Régression statistique			-
Régression additive généralisée (GAM)	Régression fortement non linéaire, robuste, locale	Régression statistique			-
Régression isotonique	Régression non linéaire monotone	Régression statistique			Standardisation
Régression Généralisée (GLM)	Régression non linéaire	Régression statistique			Standardisation
Quantile regression	Régression fortement non linéaire, robuste, présence d'hétéros-cédasticité	Régression statistique		pinball loss	Standardisation
Processus gaussiens (GP)	Régression fortement non linéaire	Régression statistique			-
Huber regression	Régression fortement non linéaire, robuste, insensible aux outliers	Régression statistique		huber loss	-
Régression PLS	Régression non linéaire avec analyse des composantes principales	Régression non supervisée			Standardisation
KNN regression	Régression locale / ponctuelle avec beaucoup de données	Régression statistique	$\hat{y} = \frac{1}{k} \sum_{i \in \mathcal{N}_k(x)} y_i$	$\sum_{i=1}^{n}(y_i - \hat{y_i})^2$	Standardisation

TABLE 4.1 – Synthèse des modèles de Machine Learning - régression

Modèle	Quand l'utiliser	Paradigme	Formule	Quantité à minimiser	Préparation des données
SVM (Support Vector Machine)	Classification fortement non linéaire à marge dure	Classification supervisée	$\hat{y_i} = \text{sign}(w^T x_i + b)$	$\frac{1}{2}\|\|w\|\|^2$	Standardisation
CSV-C (C-Suport Vector Classification)	Régression fortement non linéaire avec tolérance aux marges (hyperparamètre non borné)	Classification supervisée	$\hat{y_i} = \text{sign}(\sum_{i=1}^{n} \alpha_i y_i K(x_i, x_j) + b)$	$\frac{1}{2}\|\|w\|\|^2 + C\sum_{i=1}^{n} \xi_i$	Standardisation
ν-SVM (ν-Suport Vector Machine)	Régression fortement non linéaire avec tolérance aux marges (hyperparamètre borné)	Classification supervisée	$\hat{y_i} = \text{sign}(\sum_{i=1}^{n} \alpha_i y_i K(x_i, x_j) + b)$	$\frac{1}{2}\|\|w\|\|^2 - \nu\rho + \frac{1}{n}\sum_{i=1}^{n} \xi_i$	Standardisation
SVR / ϵ-SVM (Support Vector Regressor)	Régression fortement non linéaire	Régression supervisée	$\hat{y_i} = \sum_{i=1}^{n}(\alpha_i - \alpha_i^*)K(x_i, x) + b$	$\frac{1}{2}\|\|w\|\|^2 + C\sum_{i=1}^{n}(\xi_i + \xi_i^*)$	Standardisation
ν-SVR (ν-Support Vector Regressor)	Régression fortement non linéaire	Régression supervisée	$\hat{y_i} = \sum_{i=1}^{n}(\alpha_i - \alpha_i^*)K(x_i, x) + b$	$\frac{1}{2}\|\|w\|\|^2 + C(\nu\epsilon + \frac{1}{n}\sum_{i=1}^{n}(\xi_i + \xi_i^*))$	Standardisation

TABLE 4.2 – Synthèse des modèles de Machine Learning - vecteurs support

Modèle	Quand l'utiliser	Paradigme	Formule	Quantité à minimiser	Préparation des données
Decision tree	Classification	Classification supervisée	Partitionnement récursif	$\sum_{i=1}^{n}(y_i - \hat{y_i})$ dans les feuilles	-
Random Forest	Classification, robustesse, relations non linéaires	Méthode ensembliste (classification)	Moyenne ou classe majoritaire des arbres	$\sum_{i=1}^{n}(y_i - \hat{y_i})$ out-of-bag	-
Gradient Boosting / XGBoost	Classification, robustesse, relations fortement non linéaire	Ensemble boosting	Actualisation d'un arbre faible	$-\sum y \log(\hat{y})$	-

TABLE 4.3 – Synthèse des modèles de Machine Learning - méthodes d'ensemble

Modèle	Quand l'utiliser	Paradigme	Formule	Quantité à minimiser	Préparation des données
AR	Séries temporelles	Modèle autorégressif		-	Stationnarité
MA	Séries temporelles	Modèle autorégressif		-	Stationnarité
ARMA	Séries temporelles	Modèle autorégressif		-	Stationnarité
ARIMA	Séries temporelles	Modèle autorégressif		-	Stationnarité
SARIMA	Séries temporelles, saisonnarité	Modèle autorégressif		-	Stationnarité
SARIMAX	Séries temporelles, saisonnarité avec variables exogènes	Modèle autorégressif		-	Stationnarité

TABLE 4.4 – Synthèse des modèles de Machine Learning - processus autorégressifs

Modèle	Quand l'utiliser	Paradigme	Formule	Quantité à minimiser	Préparation des données
AR	Séries temporelles	Modèle autorégressif		-	Stationnarité

TABLE 4.5 – Synthèse des modèles de Machine Learning - clustering

Modèle	Quand l'utiliser	Paradigme	Formule	Quantité à minimiser	Préparation des données
AR	Séries temporelles	Modèle autorégressif		-	Stationnarité

TABLE 4.6 – Synthèse des modèles de Machine Learning - réduction de dimension

5 | Mathématiques complémentaires

5.1 Motivations

L'objectif de ce chapitre est de donner des notions, termes et concepts mathématiques permettant de faciliter la compréhension globale des mathématiques dissimulés derrière l'apprentissage automatique et la mise en application des modèles d'IA.

5.2 Distance, normes et produits scalaires

5.2.1 Distance

Une distance est une application de $E \times E$ dans $\mathbb{R}^+$ tel que

- $\forall x, y \in E, d(x, y) = d(y, x)$ (symétrie)
- $\forall x, y \in E, d(x, y) = 0 \iff x = y$ (séparation)
- $\forall x, y \in E, d(x, y) \leq d(x, z) + d(y, z)$ (inégalité triangulaire)

5.2.2 Norme

Une norme est une application de E dans $\mathbb{R}^+$ tel que

- $\forall x \in E, \mathcal{N}(x) = 0 \implies x = 0_E$ (séparation)
- $\forall \lambda, x \in K \times E, \mathcal{N}(\lambda x) = |\lambda| \mathcal{N}(x)$ (homogénéité)
- $\forall x, y \in E, \mathcal{N}(x + y) \leq \mathcal{N}(x) + \mathcal{N}(y)$ (inégalité triangulaire)

5.2.3 Produit scalaire

Un produit scalaire est une application bilinéaire semie définie positive, i.e.

- $\forall x, y \in E, \langle x, y\rangle = \langle y, x\rangle$ (symétrie)
- $x \in E, \langle x, x\rangle = 0 \Longleftrightarrow x = 0_E$ (définie)
- $x \in E, \langle x, x\rangle \leq 0$ (positive)

Le produit scalaire est définit de la manière suivante pour deux vecteurs x et y dans $\mathbb{R}^n$

$$\langle x, y\rangle = \sum_{i=1}^{n} x_i y_i \tag{5.1}$$

La norme et la distance euclidienne découlent du produit scalaire de la manière suivante

$$||x|| = \sqrt{\langle x, x\rangle} \tag{5.2}$$

$$d(x, y) = ||x - y|| \tag{5.3}$$

5.2.4 Produit hermitien

Le produit scalaire hermitien étend la notion de produit scalaire pour le coprs des complexes. C'est une application sesquilinéaire définie positive symétrique hermitienne de $H \times H$ dans $\mathbb{C}$, i.e.

- $\forall x, y \in H, \mu \in \mathbb{C}, \langle x, \mu y\rangle = \mu\langle x, y\rangle$ (linéaire relativement au second argument pour la sesquilinéarité à gauche)
- $\forall x, y \in H, \lambda \in \mathbb{C}, \langle \lambda x, y\rangle = \bar{\lambda}\langle x, y\rangle$ (semi-linéaire relativement au premier argument pour la sesquilinéarité à gauche)
- $\forall x, y \in H, \langle x, \mu y\rangle = \langle y, \bar{\mu} x\rangle$ (symétrique hermitienne)
- $\forall x \in E, \langle x, x\rangle \in \mathbb{R}^+$ (positive)
- $\forall x \in E, \langle x, x\rangle = 0 \Longleftrightarrow x = 0_H$ (définie)

Une application semi-linéaire respecte les conditions suivantes

- $\forall x, y \in E, f(x + y) = f(x) + f(y)$
- $\forall x \in E, \lambda \in \mathbb{C}, f(\lambda x) = \bar{\lambda} f(x)$

5.3 Topologie

5.3.1 Complétude.

Un espace E est complet si toute suite de Cauchy converge dans E. Une suite de Cauchy est une suite réelle ou complexe $(u_n)_{n\in\mathbb{N}}$ telle que

$$\forall \epsilon > 0, \exists N \in \mathbb{N}, \forall p, q \geq N, |u_p - u_q| < 0 \tag{5.4}$$

Intuitivement, les points qui se rapprochents de plus en plus les uns les autres forment une suite qui converge vers une limite qui existe et se trouve à l'intérieur de E. Autrement dit, il n'y a aucun trou dans E.

5.3.2 Corps commutatif.

Un corps commutatif (ou tout simplement un corps) $(\mathbb{K}, +, \times)$ est un ensemble muni de deux lois internes (souvent $+$ et $\times$, rendant possibles les opérations d'addition, de soustraction, de multiplication et de division). Ces lois doivent vérifier les conditions suivantes :

- $(\mathbb{K}, +)$ forme un groupe abélien (groupe dont la loi est commutative, i.e. $\forall a, b \in E, a + b = b + a$) dont l'élément neutre est noté 0
- $(\mathbb{K}\, 0, \times)$ forme un groupe abélien (ici, $\forall a, b \in E, a \times b = b \times a$) dont l'élément neutre est noté 1
- La multiplication est distributive par rapport à l'addition, i.e. $a \times (b + c) = a \times b + a \times c$ et $(b + c) \times a = b \times a + c \times a$

$(\mathbb{R}, +, \times)$ et $(\mathbb{C}, +, \times)$ sont des corps commutatifs que l'on note abusivement $\mathbb{R}$ et $\mathbb{C}$.

5.3.3 Espace topologique.

Nous pouvons définir une topologie T sur un ensemble E si T est un ensemble de parties de E qui vérifie :

- $E \in T$ et $\emptyset \in T$
- T est stable par intersection finie, i.e. si $U_1, U_2 \in T$, alors $U_1 \cap U_2 \in T$
- T est stable par réunion quelconque, i.e. si $\forall i \in \mathcal{I}, U_i \in T$, alors $\bigcup_{n\in\mathbb{N}} U_i \in T$

Les espaces topologiques permettent, lorsque nous les munissons d'outils géométriques et algébriques, d'engendrer des espaces plus riches. Notons que les ensembles permettent de construire une topologie et non l'inverse.

5.3.4 Espace métrique.

Un espace métrique est un couple (E, d) ou E est un ensemble et d une distance.

5.3.5 Espace vectoriel normé.

Soit $\mathbb{K}$ un corps commutatif muni d'une valeur absolue et non discret ($\mathbb{R}$ ou $\mathbb{C}$). Un $\mathbb{K}$-espace vectoriel normé est un couple $(V, \mathcal{N})$ ou E est un $\mathbb{K}$-espace vectoriel et $\mathcal{N}$ une norme.

5.3.6 Espace euclidien.

Un espace euclidien est un espace vectoriel de dimension finie (par conséquent complet) $(E, \langle ., . \rangle)$ sur le corps des réels dont la norme découle d'un produit scalaire.

5.3.7 Espace hermitien.

Un espace hermitien est un espace vectoriel de dimension finie sur le corps des complexes (par conséquent complet) $(\mathcal{H}, \langle ., . \rangle)$ dont la norme découle d'un produit (scalaire) hermitien.

5.3.8 Espace de Banach.

Un espace de Banach est un espace vectoriel normé sur le corps des complexes dont la distance est issue de sa norme.

5.3.9 Espace de Hilbert ou hilbertien et préhilbertien.

Un espace hilbertien est un espace euclidien ou hermitien de dimension finie ou infinie. C'est le cas le plus général. Notons qu'un espace hilbertien est forcément complet, ce qui n'est pas garanti pour

un espace préhilbertien. Les espaces hermitiens et euclidien sont complets car de dimension finie et hermitiens. La notion de complétude est en effet plus ambigue pour les espaces de dimension infinie.

5.3.10 Espace ouvert et fermé.

Il existe plusieurs définitions d'un espace ouvert en fonction de quel élément est muni l'espace considéré. Dans un cas général ou cet espace est topologique, démuni d'une norme ou un produit sclaire par exemple, un sous ensemble U de E est un ouvert de E pour la topologie T si et seulement si $U \in T$. T devient l'ensemble des ouverts de E selon T.

- Pour les espaces métriques, un espace ouvert $U \subset E$ est une une boule ouverte définie par : $B(a,r) = \{x \in E \quad | \quad d(a,r) < r\}$. Les boules fermées sont définies par $B(a,r) = \{x \in E \quad | \quad d(a,r) < r\}$

- Pour les espaces de Hilbert, un une partie $U \subset \mathcal{H}$ est ouverte si elle est le voisinage de chacun de ses points. Pour la notion de topologie forte, (les notions de topologie forte et faible ont étés introduites pour les espaces de dimension infinie), la définition du voisinage est la suivante

$$\forall \boldsymbol{x} \in U \subset \mathcal{H}, \exists r > 0, B(\boldsymbol{x}, r) \subset U, \quad B(\boldsymbol{x}, r) = \{y \in \mathcal{H}, ||x - y|| = d(x, y) < r\} \tag{5.5}$$

Pour la topologie faible, la notion de voisinage est la suivante

$$\boldsymbol{\mathcal{V}}(\boldsymbol{x}) = \{\boldsymbol{y} \in \mathcal{H}, |\langle \boldsymbol{y} - \boldsymbol{x}, \boldsymbol{h}_i \rangle| < \epsilon, i \in [\![1, n]\!], \boldsymbol{h}_i \in \mathcal{H}\} \tag{5.6}$$

5.3.11 Espace L^p

Un espace L^p, ou espace de Lebesgue, est un espace vectoriel de la classe des fonctions d'exposant $p > 0$ intégrable au sens de Lebesgue. La norme dans cet espace est

$$||f||_p = \left(\int_a^b |f(t)|^p dt \right)^{\frac{1}{p}} \tag{5.7}$$

La définition s'étend à la notion de fonctions mesurables sur un espace mesuré $(X, \mathcal{A}, \mu)$

$$||f||_p = \left(\int_a^b |f|^p d\mu \right)^{\frac{1}{p}} \tag{5.8}$$

5.3.12 Espace de Sobolev.

Un espace de Sobolev est un espace fonctionnel (ensemble d'applications d'un espace $\mathcal{X}$ vers un espace $\mathcal{Y}$, i.e. un espace vectoriel de fonctions) dont la norme est obtenue par la combinaison de la normle L^p. La notion d'espace de Sobolev intervient notament lors de l'étude des dérivées droites ou partielles d'une fonction. C'est également un espace de Banach Soient Ω un ouvert de $\mathbb{R}^n$, $p \in [1; +\infty]$ et m un entier naturel. On défnit l'espace de Sobolev par

$$W^{m,p} = \{u \in L^p(\Omega) \quad | \quad \forall \alpha, |\alpha| \leq m, \quad D^\alpha u \in L^p(\Omega)\} \tag{5.9}$$

Avec $D^\alpha u$ une dérivée partielle de u au sens des distribution (faible). La norme pour cet espace est définie par

$$||u||_{W^{m,p}} = \begin{cases} \left(\sum_{|\alpha| \leq m} ||D^\alpha u||_{L^p}^p \right)^{\frac{1}{p}} & \text{si1} \quad \leq p \leq +\infty \\ \max_{|\alpha| \leq m} ||D^\alpha u||_\infty & \text{si} \quad p = +\infty \end{cases} \tag{5.10}$$

5.3.13 Notion de voisinage.

Soit E un espace topologique et $\boldsymbol{a} \in E$. Une partie V de E est un voisinage de $\boldsymbol{a}$ si et seulement si il existe un ouvert U tel que :

$$\boldsymbol{a} \in U \subset V \tag{5.11}$$

Nous notons $\boldsymbol{\mathcal{V}}(\boldsymbol{a})$ l'ensemble des voisinages de $\boldsymbol{a}$. Par conséquent, nous remarquons les propriétés suivantes :

- $V \in \boldsymbol{\mathcal{V}}(\boldsymbol{a}) \wedge V \subset W \subset E \implies W \in \boldsymbol{\mathcal{V}}(\boldsymbol{a})$
- $(V, W) \in (\boldsymbol{\mathcal{V}}(\boldsymbol{a}))^2 \implies V \cap W \in \boldsymbol{\mathcal{V}}(\boldsymbol{a})$
- $E \in \boldsymbol{\mathcal{V}}(\boldsymbol{a})$
- $\emptyset \in \boldsymbol{\mathcal{V}}(\boldsymbol{a})$

A titre d'exemple, sur la droite réelle $\mathbb{R}$, un voisinage de $x \in \mathbb{R}$ est l'ensemble $]x - \epsilon; x + \epsilon[, \epsilon > 0$. D'après les conséquences de la définition, en prennant $U = V = E$, $\mathbb{R}$ est un voisinage de tout point x de $\mathbb{R}$.

5.4 Intégrabilité

5.4.1 Intégrabilité (Riemann).

Une fonction $f : \mathcal{I} \to \mathbb{K}$ est dite intégrable au sens de Riemann si $\int_{\mathcal{I}} |f|$ existe, i.e. nous notons $\forall c \in \mathcal{I}, \phi_c : \mathcal{I} \leftarrow \mathbb{R}, x \longrightarrow \int_c^x |f|$, f est Riemann-intégrable si et seulement si $\forall c \in \mathcal{I}, \phi_c$ admet des limites en a et en b et $\exists c \in \mathcal{I}, \phi_c$ admette des limites finies en a et en b.

5.4.2 Intégrabilité (Lebesgue).

L'intégrale de Lebesgue est une généralisation de l'intégrale de Riemann permettant d'étendre la notion d'intégrale à des ensembles plus généraux que $\mathbb{R}$ ou $\mathbb{R}^n$. Soient $(X, \mathcal{A}, \mu)$ un espace mesuré. Soit f une fonction $\mathcal{A}$-mesurable de X dans $\bar{\mathbb{R}}$ ou $\mathbb{C}$. f est Lebesgue-intégrable si

$$\int_X |f(x)| d\mu(x) < +\infty \tag{5.12}$$

5.5 Distributions.

5.5.1 Support compact.

Le support d'une fonction f est un ensemble d'éléments dont l'image de f par $x \in X$ est non nulle. Autrement dit, $\texttt{supp}(f) = \{x \in \bar{X}, \quad f(x) \neq 0\}$. Soit un espace métrique (X, d). (X, d) est un compact si et seulement si $\forall (x_n)_{n \in \mathbb{N}}$, il existe une sous suite (x_{n_k}) qui converge dans X. La

conséquence de cette définition est que, en dimension finie, un tel espace est un fermé borné.

5.5.2 Fonction test

Une fonction test est une fonction de classe C^∞ à support compact que nous noterons K. Par exemple, la fonction

$$\phi(x) = \begin{cases} e^{\frac{-1}{1-x^2}} & \text{si} |x| < 1 \\ 0 & \text{sinon} \end{cases} \quad \text{est une fonction test.}$$

5.5.3 Théorie des distributions.

Une distribution est une généralisation de la notion de fonction et de mesure. Cette extension permet notament de dériver des fonctions discontinues ou mal définies au sens classique de la dérivation. Contrairement à la définition classique d'une fonction qui évalue la valeur de l'image point par point, une distribution calcule une moyenne des valeurs d'une fonction dans un domaine resserré autour du point d'étude. Les moyennes sont pondérées et conduisent à étudier une expression de la forme

$$I_f(\phi) = \int_{\mathbb{R}} f(x)\phi(x)dx \tag{5.13}$$

La fonction à évaluer est $f : \mathbb{R} \to \mathbb{R}$ une fonction localement intégrable et $\phi : \mathbb{R} \to \mathbb{R}$ une fonction indéfiniment dérivable appelée fonction test.

5.6 Théorie de l'apprentissage

5.6.1 Apprentissage PAC.

La notion de voisinage renvoie à un ensemble qui peut être aussi grand que l'on souhaite, sous réserve d'être au plus de la même taille que E. Selon la théorie de l'apprentissage PAC (Probablement Approximativement Correct), nous définissons un estimateur h de la vérité terrain $\boldsymbol{a}$ dans l'espace latent $E = \mathcal{Y}$ comme une fonction de $\mathcal{X}$ dans $\mathcal{Y}$ tel que $h(\boldsymbol{x}) = \hat{\boldsymbol{a}}$, $\boldsymbol{x}$ étant le vecteur d'entrée $\boldsymbol{x} \in \mathcal{X}$ et $\in \mathcal{Y}$ un estimateur de $\boldsymbol{a} \in \mathcal{Y}$. La meilleure estimation de $\boldsymbol{a}$ est noté $\boldsymbol{a}^*$ associé au meilleur estimateur h^* du modèle M vérifie la condition suivante

$$\boldsymbol{a}^* = \arg\min_{h \in \mathcal{H}} \mathcal{R}_S(h) = \arg\min_{\hat{\boldsymbol{a}}, \boldsymbol{a} \in \mathcal{Y}^2} \mathbb{E}\left[L(\boldsymbol{a}, \hat{\boldsymbol{a}})\right]$$

L'algorithme A fournit un bon estimateur de la solution si et seulement si il a l'apprentissage PAC, i.e.

$$\mathbb{P}\left(\boldsymbol{a}^* \in \mathcal{V}(\boldsymbol{a})\right) \geq 1 - \epsilon, \quad \epsilon > 0 \tag{5.14}$$

Si le voisinage $\boldsymbol{\mathcal{V}}(\boldsymbol{a})$ peut prendre la taille de E, alors cette probabilité tend vers 1, même pour le pire estimateur de $\boldsymbol{a}$. Cette définition est par conséquent incomplète car nous devons, par nécéssité, contrôler la taille de $\boldsymbol{\mathcal{V}}(\boldsymbol{a})$. Pour cela, nous munissons de l'espace topologique E une distance d qui permet de restreindre $\mathcal{V}(\boldsymbol{a})$ à une boule ouverte B tel que :

$$\boldsymbol{\mathcal{V}}(\boldsymbol{a}) = B(\boldsymbol{a}^*, \eta) = \{\boldsymbol{z} \in E \mid d(\boldsymbol{z}, \boldsymbol{a}^*) < \eta\} \tag{5.15}$$

La définition d'un algorithme A aillant l'apprentissage PAC complète prend alors la forme :

$$\mathbb{P}\left(\boldsymbol{a}^* = h^*(\boldsymbol{x}) \in B(\boldsymbol{a}, \eta)\right) \geq 1 - \epsilon, \quad \epsilon > 0 \tag{5.16}$$

5.7 Complétude, tribu, mesure

5.7.1 Complémentarité.

Soit E un espace vectoriel. Soient F et G deux espaces dans E. G et F sont complémentaires si et seulement si

- $\forall f \in F, \forall g \in G, f + g = e \in E$, i.e. $F + G = E$
- $F \cap G = \{0\}$

Dans ce cas, nous notons le complémentaire de F F^c et par conséquent $F^c = G$. Il en va de même que $G^c = F$, et nous écrivons que F et G sont en somme directe, à savoir que $F \oplus G = E$

5.7.2 Tribu.

Si $\mathcal{A}$ est un tribu sur X, alors $\mathcal{A}$ est un ensemble non vide de parties de X stable par passage au complémentaire et par union dénombrable, i.e.

- $\mathcal{A}$ contient $\varnothing$
- $\forall B \in \mathcal{A}, B^c \in \mathcal{A}$ (B^c est le complémentaire de B dans $\mathcal{A}$)
- Si, $\forall n \in \mathbb{N}, B_n \in \mathcal{A}$ alors $\bigcup_{n\in\mathbb{N}} B_n \in \mathcal{A}_n$

5.7.3 Espace mesurable

Un espace mesurable est un couple $(X, \mathcal{A})$, $\mathcal{A}$ tribu sur X. $a \in \mathcal{A}$ est un ensemble mesurable de X. Nous ajoutons une mesure μ qui permet de construire un espace mesuré $(X, \mathcal{A}, \mu)$

5.7.4 Tribu image réciproque

Soient $(X_1, \mathcal{A}_1)$ et $(X_2, \mathcal{A}_2)$ deux espaces mesurables et f une application $f : X_1 \to X_2$, la tribu image réciproque de $\mathcal{A}_\in$ sous f est l'ensemble $f^{-1}(\mathcal{A}_2)$ définit par :

$$f^{-1}(\mathcal{A}_2) = \left\{ f^{-1}(\mathcal{A}_2) | \mathcal{A}_2 \in X_2 \right\} \tag{5.17}$$

$f^{-1}(\mathcal{A}_2)$ est une tribu sur X_1.

5.7.5 Fonction mesurable

Une fonction $f : E \to F$ est $(\mathcal{E}, \mathcal{F})$-mesurable si la tribu image réciproque par f de la tribu $\mathcal{F}$ est incluse dans $\mathcal{E}$, c'est à dire si :

$$\forall B \in \mathcal{F}, \quad f^{-1}(B) \in \mathcal{E}$$

5.7.6 Fonction différentiable.

Soit f définie sur un ouvert U de $\mathbb{R}^n$ à valeurs dans $\mathbb{R}^p$. Soit $\boldsymbol{a} \in U$. f est différentiable en $\boldsymbol{a}$ si et seulement si $\exists! L : \mathbb{R}^n \to \mathbb{R}^p$ tel que

$$f(\boldsymbol{a} + h) =_0 f(\boldsymbol{a}) + L(h) + o(||h||) \tag{5.18}$$

Si L existe, alors L est la différentielle de f en $\boldsymbol{a}$, et nous notons $L = df(\boldsymbol{a})$. De plus, f est différentiable en U si et seulement si $\forall \boldsymbol{a} \in U$, f est différentiable en $\boldsymbol{a}$. A titre d'exemple, sur $\mathbb{R}$, nous retrouvons la définition fondamentale de la dérivée, à savoir que l'on a $f(a+h) = f(a)+L(h)+o(h)$, soit

$$lim_{h\to 0}\frac{f(a+h)-f(h)}{h} = L(a) = f'(a) \tag{5.19}$$

5.7.7 Gradient.

Soit f une fonction de $\mathbb{R}^n$ dans $\mathbb{R}^n$. Le gradient de f en $\boldsymbol{x} \in \mathbb{R}^n$, noté ∇f, est donné par la définition suivante

$$\nabla f(\boldsymbol{x}) = \left[\frac{\partial f}{\partial x_1}(\boldsymbol{x}), \ldots, \frac{\partial f}{\partial x_n}(\boldsymbol{x})\right]^T \tag{5.20}$$

5.7.8 Application Lipschitzienne.

Soit E une partie de $\mathbb{R}$ et $f : E \to \mathbb{R}$. f est k-Lipschitzienne si et seulement si $\forall (x, y) \in E^2$,

$$|f(x) - f(y)| \leq k|x - y| \tag{5.21}$$

5.7.9 ∇f Lipschitz continuité.

f est ∇f Lipschitz-continue sur $\mathcal{I}$ si et seulement si $\forall \boldsymbol{x}, \boldsymbol{y} \in \mathcal{I}, ||\nabla f(\boldsymbol{x}) - \nabla f(\boldsymbol{y})|| \leq L||\boldsymbol{x} - \boldsymbol{y}||, L > 0$

5.8 Autre

5.8.1 Théorème fondamental des splines de lissage - Théorème de représentation.

Pour un problème d'optimisation avec terme de régularisation dans un espace de fonctions de dimension infinie, il y a existence et unicité d'une solution dans un espace de dimension finie dont la solution est une fonction spline.

Le terme de régularisation par la dérivée m-ième de la fonction à minimiser garanti une solution unique par une spline d'ordre $2m-1$. Autrement dit, soient un ensemble de N observations (noeuds) distincts $(x_i, y_i)_{i \in mathbbN^*}$, $\mathcal{H}_m([a;b])$ un espace de Sobolev de fonctions définies sur $[a;b]$ dont les dérivées sont absolument continues jusqu'à l'odre $m-1$ et la dérivée m-ième est de carré intégrable, i.e. $f^{(m)} \in \mathcal{L}_2([a;b])$ alors $\exists! \hat{f}$,

$$\forall \lambda > 0, \quad \hat{f} = \arg \min_{f \in \mathcal{H}_m([a;b])} \sum_{i=1}^{N} (y_i - \underbrace{f(x_i)}_{=\hat{y}_i})^2 + \lambda \int_a^b (f^{(m)}(x))^2 dt \tag{5.22}$$

et $\hat{f}$ est une spline d'ordre $2m-1$, i.e.

$$\forall x \in [a;b], \quad \hat{f}(x) = \sum_{i=0}^{m-1} \beta_i x^i + \sum_{i=1}^{N} \gamma_i \underbrace{(x - x_i)_+^{2m-1}}_{=\max(0, x-x_i)^{2m-1}} \tag{5.23}$$